

Análise Comparativa de Arquiteturas Convolucionais para Classificação Morfológica de Galáxias

Geovanna de Paula Medeiros
Engenharia de Software
Universidade de Brasília
Brasília, Brasil
252023198@aluno.unb.br

Renan Curione de Castro
Engenharia de Software
Universidade de Brasília
Brasília, Brasil
242024834@aluno.unb.br

Abstract—A classificação morfológica de galáxias é uma tarefa relevante na análise de grandes levantamentos astronômicos, cujo volume de dados torna inviável a inspeção manual de todas as imagens. Este trabalho apresenta uma comparação entre as arquiteturas ResNet18, GoogLeNet e MobileNetV3 Small para essa tarefa, utilizando 155.951 imagens distribuídas em oito classes. Os modelos foram treinados com pesos pré-treinados no ImageNet e ajuste fino de toda a rede, empregando aumento de dados e ponderação das classes. A avaliação considerou acurácia, precisão, *recall* e F1-score, incluindo médias macro e ponderada, além do desempenho por classe e do custo computacional. A GoogLeNet obteve o melhor resultado geral, com 80,20% de acurácia e 74,40% de F1-score macro. A MobileNetV3 Small alcançou 78,19% de acurácia e 72,29% de F1-score macro, utilizando apenas 1,53 milhão de parâmetros. Os resultados evidenciam um compromisso entre desempenho preditivo e custo computacional na escolha da arquitetura.

Index Terms—classificação morfológica, galáxias, Galaxy Zoo, redes neurais convolucionais, ResNet18, GoogLeNet, MobileNetV3

I. INTRODUÇÃO

O avanço dos levantamentos astronômicos tem produzido grandes volumes de imagens, tornando impraticável a inspeção individual de todos os objetos por especialistas e motivando métodos automatizados de análise em larga escala [1], [2].

Entre essas tarefas destaca-se a classificação morfológica de galáxias, que categoriza os objetos segundo características estruturais e visuais. Essa classificação é relevante para estudos de formação e evolução galáctica, pois a morfologia está associada a propriedades e processos físicos desses objetos [1], [2]. O Galaxy Zoo demonstrou a viabilidade de obter classificações morfológicas em larga escala por meio de ciência cidadã [1].

Redes Neurais Convolucionais (*Convolutional Neural Networks* – CNNs) passaram a ser empregadas para automatizar essa tarefa, aprendendo representações hierárquicas diretamente das imagens [3]. Trabalhos anteriores demonstraram sua aplicabilidade à classificação morfológica de galáxias [4], [5].

Diferentes arquiteturas apresentam estratégias distintas de extração de características. A ResNet utiliza conexões residuais [6]; a GoogLeNet emprega módulos Inception para

processar características em diferentes escalas [7]; e a MobileNetV3 foi projetada visando eficiência computacional [8]. Assim, este trabalho compara ResNet18, GoogLeNet e MobileNetV3 Small sob condições experimentais controladas, considerando desempenho, comportamento por classe, número de parâmetros e custo computacional.

II. FUNDAMENTAÇÃO TEÓRICA

A. Redes Neurais Convolucionais

CNNs são redes profundas adequadas ao processamento de imagens. Seus filtros convolucionais aprendem características locais e, por meio de camadas sucessivas, constroem representações em diferentes níveis de abstração [3]. Considerando uma entrada X , um filtro K e um viés b , uma convolução pode ser representada por

$$Y_{i,j} = \sum_m \sum_n X_{i+m,j+n} K_{m,n} + b. \quad (1)$$

As camadas iniciais aprendem padrões locais, enquanto camadas posteriores combinam essas informações para formar representações mais abstratas utilizadas pela classificação.

B. Arquiteturas Avaliadas

A ResNet utiliza conexões residuais, nas quais a entrada de um bloco é combinada à transformação aprendida, facilitando a otimização de redes profundas [6]. A ResNet18 é a configuração utilizada neste trabalho.

A GoogLeNet emprega módulos Inception, que realizam operações em paralelo para extrair características em diferentes escalas [7]. Durante o treinamento, seus classificadores auxiliares também são utilizados, com perda

$$L = L_{\text{main}} + 0.3L_{\text{aux1}} + 0.3L_{\text{aux2}}. \quad (2)$$

Na validação e no teste, somente a saída principal é considerada.

A MobileNetV3 foi desenvolvida com foco na eficiência computacional [8]. Sua variante Small é utilizada como arquitetura de menor complexidade estrutural na comparação.

C. Transferência de Aprendizado e Regularização

Os três modelos foram inicializados com pesos pré-treinados no ImageNet e submetidos a ajuste fino de toda a rede. Assim, tanto o extrator convolucional quanto a cabeça de classificação puderam adaptar seus parâmetros ao domínio das imagens de galáxias.

Como estratégias de regularização, foram utilizados *weight decay*, aumento de dados e *early stopping*. O *weight decay* foi aplicado por meio do AdamW, com fator 10^{-4} [9]. O *early stopping* utilizou o F1-score macro de validação, com paciência de três épocas.

D. Métricas

A acurácia representa a proporção de previsões corretas. Precisão e *recall* medem, respectivamente, a proporção de previsões positivas corretas e a proporção de exemplos positivos corretamente identificados. O F1-score é definido por

$$F_1 = 2 \frac{PR}{P + R}, \quad (3)$$

em que P é a precisão e R o *recall*.

Foram consideradas médias macro e ponderada. A média macro calcula a média das métricas das classes atribuindo o mesmo peso a cada uma, enquanto a média ponderada considera a quantidade de exemplos de cada classe. Dessa forma, a média macro é particularmente relevante para avaliar o comportamento do modelo diante do desbalanceamento presente no conjunto de dados.

III. TRABALHOS RELACIONADOS

O Galaxy Zoo demonstrou a viabilidade de obter classificações visuais de galáxias em larga escala por meio de ciência cidadã, enquanto o Galaxy Zoo 2 ampliou a caracterização morfológica [1], [2].

Com o avanço do aprendizado profundo, CNNs passaram a ser utilizadas para automatizar a classificação morfológica. Dai e Tong investigaram redes convolucionais profundas para essa tarefa [4], enquanto Zhu et al. também avaliaram CNNs profundas [5]. Walmsley et al. estudaram aprendizado profundo aplicado a dados do Galaxy Zoo DECaLS [10]. Outras abordagens incluem Vision Transformers para classificação morfológica [11].

Embora esses trabalhos demonstrem o potencial do aprendizado profundo, diferentes arquiteturas apresentam compromissos distintos entre capacidade de representação e custo computacional. Este trabalho explora esse compromisso por meio de uma comparação controlada entre três arquiteturas convolucionais.

IV. METODOLOGIA

A. Conjunto de Dados

Foi utilizado o conjunto *Galaxy Zoo Dataset*, disponibilizado por meio do Hugging Face e derivado dos dados do Galaxy Zoo DECaLS. Sua taxonomia de oito classes segue a classificação utilizada por Lin et al. [10], [11]. O conjunto contém 155.951 imagens distribuídas entre *Round Elliptical*,

In-between Elliptical, *Cigar-shaped Elliptical*, *Edge-on Spiral*, *Barred Spiral*, *Unbarred Spiral*, *Irregular* e *Merger*.

Foram utilizadas 99.808 imagens para treinamento, 24.952 para validação e 31.191 para teste. O conjunto de teste permaneceu separado durante o treinamento e foi utilizado exclusivamente na avaliação final. Devido ao desbalanceamento entre categorias, foram utilizados pesos de classe calculados a partir das frequências do conjunto de treinamento.

B. Pré-processamento e Aumento de Dados

As imagens foram convertidas para RGB e redimensionadas para 224×224 pixels. Em seguida, foram normalizadas utilizando média (0.485, 0.456, 0.406) e desvio-padrão (0.229, 0.224, 0.225), correspondentes à normalização utilizada pelos pesos pré-treinados no ImageNet.

Durante o treinamento foram aplicados inversão horizontal aleatória, rotação de até 10° e variações de brilho e contraste de até 20%. Validação e teste utilizaram somente redimensionamento, conversão para tensor e normalização, evitando que transformações aleatórias influenciassem a avaliação.

C. Configuração Experimental

Os três modelos utilizaram pesos pré-treinados no ImageNet e ajuste fino de toda a rede. O treinamento utilizou lotes de 32 imagens, taxa de aprendizado de 10^{-4} , *weight decay* de 10^{-4} , AdamW [9] e no máximo dez épocas.

A função de perda foi a entropia cruzada categórica com pesos de classe. Na GoogLeNet, os classificadores auxiliares contribuíram adicionalmente para a perda durante o treinamento, conforme definido na Seção II. O melhor *checkpoint* foi selecionado pelo maior F1-score macro de validação, com *early stopping* após três épocas sem melhoria.

A mesma configuração de entrada, otimização, aumento de dados, ponderação de classes e critério de seleção foi aplicada às três arquiteturas, com exceção do tratamento específico da GoogLeNet para suas saídas auxiliares. Essa configuração permitiu comparar as arquiteturas sob condições experimentais equivalentes.

D. Avaliação

Foram avaliadas ResNet18, GoogLeNet e MobileNetV3 Small por meio do Torchvision com pesos pré-treinados no ImageNet. A avaliação final foi realizada no conjunto de teste utilizando o melhor *checkpoint* selecionado durante a validação.

Foram calculadas acurácia, precisão, *recall* e F1-score, considerando médias macro e ponderada, além do desempenho individual por classe. Também foram registrados o número total de parâmetros, o tempo de treinamento e a memória máxima utilizada pela GPU.

Para favorecer a reprodutibilidade, foi utilizada semente aleatória fixa igual a 42 nos principais geradores de aleatoriedade utilizados pelo experimento, juntamente com as configurações determinísticas do CUDA. Os três modelos foram submetidos ao mesmo protocolo experimental, reduzindo diferenças decorrentes de condições externas à arquitetura.

V. RESULTADOS E DISCUSSÃO

A Tabela I apresenta o desempenho dos modelos no conjunto de teste.

TABLE I
DESEMPENHO DOS MODELOS NO CONJUNTO DE TESTE.

Modelo	Acc.	F1 Macro	F1 W.	Parâmetros
ResNet18	78,69%	72,44%	79,00%	11,18M
GoogLeNet	80,20%	74,40%	80,39%	9,95M
MobileNetV3-S	78,19%	72,29%	78,53%	1,53M

A GoogLeNet apresentou o melhor desempenho geral, alcançando 80,20% de acurácia, 74,40% de F1-score macro e 80,39% de F1-score ponderado. A ResNet18 alcançou 78,69% de acurácia e 72,44% de F1 macro, enquanto a MobileNetV3 Small obteve 78,19% e 72,29%, respectivamente.

A vantagem da GoogLeNet sobre a ResNet18 foi de 1,51 ponto percentual em acurácia e 1,96 ponto percentual em F1 macro. Em relação à MobileNetV3 Small, as diferenças foram de 2,01 e 2,11 pontos percentuais. Embora a GoogLeNet tenha apresentado o melhor resultado, as três arquiteturas permaneceram relativamente próximas em desempenho global.

Em quantidade de parâmetros, a ResNet18 possui 11,18 milhões, a GoogLeNet 9,95 milhões e a MobileNetV3 Small apenas 1,53 milhão. Assim, a MobileNetV3 Small utiliza aproximadamente 86% menos parâmetros que a ResNet18, mantendo desempenho competitivo.

O custo de treinamento também apresentou diferenças. A ResNet18 levou aproximadamente 2.511 s, a GoogLeNet 3.628 s e a MobileNetV3 Small 2.546 s. A memória máxima de GPU foi de aproximadamente 0,84 GB, 1,62 GB e 0,53 GB, respectivamente. Portanto, a menor quantidade de parâmetros da MobileNetV3 Small não resultou em redução expressiva do tempo de treinamento em relação à ResNet18, mostrando que o número de parâmetros isoladamente não determina o custo computacional.

A Tabela II apresenta os F1-scores por classe.

TABLE II
F1-SCORE POR CLASSE NO CONJUNTO DE TESTE.

Classe	ResNet18	GoogLeNet	MobileNetV3-S
Round Elliptical	87,51%	87,33%	86,63%
In-between Elliptical	82,92%	83,37%	82,85%
Cigar-shaped Elliptical	65,92%	66,75%	68,60%
Edge-on Spiral	85,05%	86,77%	85,96%
Barred Spiral	81,00%	82,69%	78,02%
Unbarred Spiral	70,02%	73,52%	69,72%
Irregular	50,51%	54,06%	49,58%
Merger	56,59%	60,73%	56,93%

Na GoogLeNet, *Round Elliptical* e *Edge-on Spiral* apresentaram os maiores F1-scores, com 87,33% e 86,77%. *In-between Elliptical* e *Barred Spiral* também apresentaram desempenho elevado, com 83,37% e 82,69%.

Em contraste, *Irregular* e *Merger* apresentaram os menores F1-scores, de 54,06% e 60,73%, respectivamente. *Cigar-shaped Elliptical* também apresentou desempenho inferior, com 66,75%. As classes *Irregular* e *Merger* possuem 1.176

e 407 exemplos no conjunto de teste, respectivamente. A ponderação das classes aumenta sua contribuição para a função de perda durante o treinamento, mas não elimina as dificuldades observadas na classificação.

Para a GoogLeNet, o F1-score macro foi de 74,40%, enquanto o ponderado foi de 80,39%. Essa diferença indica que o desempenho agregado é favorecido pelas classes mais numerosas, reforçando a importância da média macro para uma análise menos dependente da distribuição das categorias.

A análise das demais métricas macro reforça esse comportamento. A GoogLeNet apresentou precisão macro de 72,45% e *recall* macro de 78,32%, enquanto a ResNet18 obteve 70,26% e 78,17%, respectivamente. A MobileNetV3 Small apresentou 70,06% de precisão macro e 76,14% de *recall* macro. Assim, a GoogLeNet apresentou simultaneamente os maiores valores de precisão, *recall* e F1-score macro, embora a diferença de *recall* para a ResNet18 tenha sido pequena.

A comparação por classe também mostra que nenhuma arquitetura foi superior em todas as categorias. A GoogLeNet apresentou o melhor F1-score em seis das oito classes, enquanto a MobileNetV3 Small obteve o melhor resultado em *Cigar-shaped Elliptical* e a ResNet18 em *Round Elliptical*. Ainda assim, a GoogLeNet apresentou a maior média macro e a maior acurácia geral.

A MobileNetV3 Small apresentou uma relação favorável entre tamanho e desempenho. Seus 1,53 milhões de parâmetros correspondem a aproximadamente 13,65% da quantidade presente na ResNet18 e 15,33% da quantidade presente na GoogLeNet. Apesar dessa redução substancial, seu F1-score macro foi apenas 0,15 ponto percentual inferior ao da ResNet18. Esse resultado mostra que a redução da capacidade paramétrica não implicou perda proporcional de desempenho no conjunto avaliado.

O tempo de treinamento apresentou comportamento diferente do número de parâmetros. A GoogLeNet, mesmo possuindo menos parâmetros que a ResNet18, demandou aproximadamente 44,5% mais tempo de treinamento e utilizou quase o dobro da memória máxima de GPU. Já a MobileNetV3 Small apresentou tempo de treinamento próximo ao da ResNet18, mas utilizou a menor quantidade de memória entre os três modelos. Portanto, parâmetros, tempo de treinamento e memória devem ser analisados conjuntamente ao avaliar a eficiência de uma arquitetura.

Outro aspecto relevante é a diferença entre o número máximo de épocas e o treinamento efetivamente realizado. A ResNet18 encerrou o treinamento após oito épocas, enquanto GoogLeNet e MobileNetV3 Small atingiram dez épocas. Como o critério de seleção foi baseado no F1-score macro de validação, o número de épocas, isoladamente, não representa superioridade de um modelo, mas reflete a evolução do desempenho de validação e a atuação do *early stopping*.

A. Limitações e Perspectivas

Apesar do desempenho obtido, a comparação considera somente três arquiteturas e uma configuração específica de hiperparâmetros. Assim, os resultados não permitem concluir

que a GoogLeNet seja superior em qualquer cenário de classificação morfológica, sendo válidos dentro do protocolo experimental adotado e do conjunto de dados utilizado.

Além disso, *Irregular* e *Merger* permaneceram entre as categorias de menor F1-score, indicando que a escolha da arquitetura não elimina as dificuldades associadas a essas classes. Investigações futuras podem avaliar estratégias de aumento de dados direcionadas às classes minoritárias, diferentes funções de perda, técnicas de balanceamento, ajustes de hiper-parâmetros e outras arquiteturas. Métodos de interpretabilidade também podem auxiliar na investigação das características morfológicas utilizadas pelos modelos durante a classificação.

VI. CONCLUSÃO

Este trabalho comparou ResNet18, GoogLeNet e MobileNetV3 Small para classificação morfológica de galáxias em 155.951 imagens distribuídas em oito classes. Os modelos foram avaliados sob um protocolo comum, utilizando pesos pré-treinados no ImageNet, ajuste fino de toda a rede, aumento de dados, ponderação das classes, AdamW e seleção do melhor *checkpoint* pelo F1-score macro de validação.

A GoogLeNet apresentou o melhor desempenho, alcançando 80,20% de acurácia e 74,40% de F1-score macro. A ResNet18 obteve 78,69% e 72,44%, enquanto a MobileNetV3 Small alcançou 78,19% e 72,29%, respectivamente. A análise por classe mostrou maior facilidade na classificação de *Round Elliptical* e *Edge-on Spiral*, enquanto *Irregular* e *Merger* permaneceram entre as categorias mais difíceis.

A MobileNetV3 Small destacou-se pela menor complexidade, com 1,53 milhão de parâmetros, aproximadamente 86% menos que a ResNet18, mantendo desempenho próximo. Entretanto, essa redução não produziu redução proporcional no tempo de treinamento. A GoogLeNet apresentou o melhor desempenho preditivo, mas também o maior custo de treinamento e consumo de memória entre os modelos avaliados.

Os resultados mostram que a escolha da arquitetura envolve um compromisso entre desempenho e custo computacional. Dentro das condições experimentais adotadas, a GoogLeNet apresentou o melhor desempenho geral, enquanto a MobileNetV3 Small mostrou-se uma alternativa de baixa complexidade e desempenho competitivo.

REFERENCES

- [1] C. J. Lintott, K. Schawinski, A. Slosar, K. Land, S. Bamford, D. Thomas, M. J. Raddick, R. C. Nichol, A. Szalay, D. Andreescu, P. Murray, and J. Vandenberg, "Galaxy zoo: Morphologies derived from visual inspection of galaxies from the sloan digital sky survey," *Monthly Notices of the Royal Astronomical Society*, vol. 389, no. 3, pp. 1179–1189, 2008.
- [2] K. W. Willett, C. J. Lintott, S. P. Bamford, K. L. Masters, B. D. Simmons, K. R. V. Casteels, E. M. Edmondson, L. F. Fortson, S. Kaviraj, W. C. Keel, T. Melvin, R. C. Nichol, M. J. Raddick, K. Schawinski, R. J. Simpson, R. A. Skibba, A. M. Smith, and D. Thomas, "Galaxy zoo 2: Detailed morphological classifications for 304,122 galaxies from the sloan digital sky survey," *Monthly Notices of the Royal Astronomical Society*, vol. 435, no. 4, pp. 2835–2860, 2013.
- [3] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [4] J.-M. Dai and J. Tong, "Galaxy morphology classification with deep convolutional neural networks," *arXiv preprint arXiv:1807.10406*, 2018.
- [5] X.-P. Zhu, J.-M. Dai, C.-J. Bian, Y. Chen, S. Chen, and C. Hu, "Galaxy morphology classification with deep convolutional neural networks," *Astrophysics and Space Science*, vol. 364, no. 4, p. 55, 2019.
- [6] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.
- [7] C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, and A. Rabinovich, "Going deeper with convolutions," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2015, pp. 1–9.
- [8] A. Howard, M. Sandler, G. Chu, L.-C. Chen, B. Chen, M. Tan, W. Wang, Y. Zhu, R. Pang, V. Vasudevan, Q. V. Le, and H. Adam, "Searching for mobilenetv3," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019, pp. 1314–1324.
- [9] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *International Conference on Learning Representations (ICLR)*, 2019.
- [10] M. Walmsley, C. Lintott, T. Geron, S. Kruk, C. Krawczyk, K. W. Willett, S. Bamford, L. S. Kelvin, L. Fortson, Y. Gal, W. Keel, K. L. Masters, V. Mehta, B. D. Simmons, R. Smethurst, L. Smith, E. M. Baeten, and C. Macmillan, "Galaxy zoo decals: Detailed visual morphology measurements from volunteers and deep learning for 314,000 galaxies," *Monthly Notices of the Royal Astronomical Society*, vol. 509, no. 3, pp. 3966–3988, 2022.
- [11] J. Y.-Y. Lin, S.-M. Liao, H.-J. Huang, W.-T. Kuo, and O. H.-M. Ou, "Galaxy morphological classification with efficient vision transformer," *arXiv preprint arXiv:2110.01024*, 2021.